ANALISIS PERBANDINGAN MODEL MACHINE LEARNING UNTUK PREDIKSI PERMINTAAN PRODUK PADA E-COMMERCE

[1] Muhammad Daffa Atha Rizq
[2] Dini Triasanti, ST., MMSI.

[1]daffathr3@gmail.com
[2] dini3asa@staff.gunadarma.ac.id

Jurusan Informatika, Fakultas Teknologi Industri, Universitas Gunadarma

ABSTRAK

Ketidakpastian permintaan menjadi salah satu permasalahan utama dalam pengelolaan operasional *E-Commerce* karena dapat berdampak langsung pada efisiensi inventaris dan kinerja bisnis, sehingga dibutuhkan model prediksi berbasis data yang mampu memberikan estimasi permintaan secara akurat dan andal. Penelitian ini bertujuan untuk mengatasi tantangan ketidakpastian permintaan dalam *E-Commerce* dengan membandingkan tiga algoritma *Machine Learning*, yaitu Random Forest, XGBoost, dan Stacking Ensemble. Pendekatan pengembangan yang digunakan adalah metode *Cross-Industry Standard Process for Data Mining* (CRISP-DM), yang mencakup Pemahaman Bisnis, Pemahaman Data, Persiapan Data, Pemodelan, Evaluasi Model, dan Penerapan. Data yang digunakan berdasarkan dataset publik "*Predict Future Sales*" dari Kaggle yang berisi data penjualan bulanan selama 34 bulan. Evaluasi performa model dilakukan menguntukkan metrik RMSE, MAE, dan R-squared. Hasil penelitian menunjukkan bahwa model XGBoost memiliki performa terbaik dengan nilai RMSE sebesar 0.626. Model terbaik kemudian diterapkan untuk membuat prediksi menyeluruh yang divisualisasikan dalam bentuk dasbor interaktif. Kesimpulan dari penelitian ini menunjukan bahwa XGBoost merupakan algoritma paling optimal dan layak diterapkan sebagai solusi prediktif untuk pengelolaan permintaan produk dalam sistem *E-Commerce*.

Kata Kunci : Prediksi Permintaan, *E-Commerce, Machine Learning*, *Random Forest*, *XGBoost*, *Stacking Ensemble,* CRISP-DM

ABSTRACT

Demand uncertainty represents a fundamental challenge in E-Commerce operations, as inaccurate demand forecasting can lead to suboptimal inventory control, increased operational costs, and reduced service levels. To address this issue, robust data-driven predictive modeling approaches are required to capture complex and nonlinear demand patterns. This study investigates demand forecasting in the E-Commerce domain through a comparative evaluation of three machine learning algorithms, namely Random Forest, XGBoost, and Stacking Ensemble. The study is conducted under the Cross-Industry Standard Process for Data Mining (CRISP-DM) framework, encompassing the phases of Business Understanding, Data Understanding, Data Preparation, Modeling, Model Evaluation, and Deployment. Experiments are performed using the publicly available "Predict Future Sales" dataset from Kaggle, which contains 34 months of aggregated monthly sales data. Model performance is assessed using Root Mean Squared Error (RMSE), Mean Absolute Error (MAE), and the coefficient of determination (R^2). The empirical results demonstrate that the XGBoost model consistently outperforms the benchmark models, achieving the lowest RMSE value of 0.626. The selected model is subsequently deployed to generate comprehensive demand forecasts and integrated into an interactive analytical dashboard to support data-driven decision-making. The findings confirm that XGBoost constitutes an effective and scalable predictive solution for demand management in E-Commerce systems.

***Keyword* :** *Demand Forecasting, E-Commerce, Machine Learning, Random Forest, XGBoost, Stacking Ensemble*, CRISP-DM

PENDAHULUAN

Perkembangan teknologi informasi yang pesat pada era digital telah mendorong transformasi meningkat dalam berbagai sektor kehidupan, termasuk sektor perdagangan. Salah satu wujud nyata dari transformasi ini adalah muncul dan

berkembangnya perdagangan elektronik atau *electronic commerce* (*E-Commerce*). *E-Commerce* merupakan aktivitas jual beli barang atau jasa yang dilakukan melalui jaringan internet, yang menawarkan kemudahan dalam akses transaksi, efisiensi waktu, serta jangkauan pasar yang luas. Perubahan gaya hidup masyarakat dan peningkatan penguntukan teknologi digital menjadikan *E-Commerce* sebagai salah satu pilar utama dalam pertumbuhan ekonomi digital.

Seiring dengan pertumbuhan industri *E-Commerce* yang pesat, para pelaku bisnis juga dihadapkan pada berbagai tantangan, salah satunya adalah ketidakpastian permintaan produk dari konsumen. Permintaan yang tidak dapat diprediksi dengan akurat dapat menimbulkan dua kondisi yang merugikan, yaitu *overstock* (kelebihan persediaan) dan *stockout* (kehabisan stok). Kelebihan persediaan dapat menyebabkan peningkatan biaya penyimpanan serta risiko barang rusak atau kedaluwarsa, sementara kekurangan stok dapat menurunkan kepuasan pelanggan dan menyebabkan kehilangan potensi pendapatan. diperlukan suatu pendekatan yang tepat dan efektif untuk melakukan prediksi permintaan secara akurat, untuk mendukung pengambilan keputusan dalam pengelolaan rantai pasok.

Salah satu pendekatan yang menjanjikan untuk mengatasi permasalahan tersebut adalah pemanfaatan teknologi *Machine Learning* (ML), yang merupakan bagian dari kecerdasan buatan (*Artificial Intelligence*). ML adalah metode komputasi yang memungkinkan sistem untuk belajar dari data historis dan mengenali pola secara otomatis, tanpa harus diprogram secara eksplisit. Algoritma ML dalam *E-Commerce* dapat digunakan untuk menganalisis data transaksi penjualan, perilaku konsumen, tren musiman, serta faktor eksternal lainnya untuk menghasilkan prediksi permintaan produk yang lebih akurat dan adaptif. Penelitian oleh Yusof (2024) melaporkan integrasi data historis transaksi, perilaku konsumen, tren musiman, dan variabel eksternal untuk memprediksi permintaan secara akurat menguntukkan *regresi, time-series, clustering,* dan *neural networks*. Hasilnya menunjukkan bahwa ML mampu mengurangi risiko *overstock, stockout*, dan menekan biaya operasional secara meningkat. (Yusof, 2024).

Penerapan ML dalam prediksi permintaan produk memiliki sejumlah

kekuatan. Salah satu keunggulan utamanya adalah kemampuan mengolah data dalam jumlah besar dan kompleks secara efisien, serta menghasilkan model prediktif yang memiliki tingkat akurasi lebih tinggi dibandingkan dengan metode tradisional, algoritma ML bersifat dinamis dan dapat menyesuaikan diri terhadap perubahan pola data dari waktu ke waktu, sehingga prediksi yang dihasilkan tetap relevan dengan kondisi pasar terkini. ML mampu mengolah data besar dan kompleks untuk menghasilkan prediksi permintaan yang lebih akurat daripada metode tradisional. Selain itu, algoritma ini bersifat adaptif dapat menyesuaikan diri terhadap perubahan pola data dari waktu ke waktu sehingga prediksi tetap relevan dengan kondisi pasar aktual. (Anchuri, 2024).

Penerapan ML memiliki kelemahan dalam implementasi teknologi ini. ML bergantung pada ketersediaan data yang berkualitas tinggi dan representatif. Data yang tidak lengkap, tidak konsisten, atau bias dapat mengurangi akurasi prediksi secara meningkat. Selain itu, pengembangan model ML membutuhkan infrastruktur teknologi yang memadai serta sumber daya manusia yang memiliki keahlian dalam bidang *data science*, yang masih menjadi tantangan bagi sebagian besar perusahaan. ML juga memiliki sejumlah keterbatasan, seperti algoritma ML sangat bergantung pada kualitas data; data yang tidak lengkap, tidak konsisten, atau bering memiliki bias dapat menurunkan akurasi model secara drastis (Mohammed, 2022).

Kehawatiran terdapat kelemahan tersebut mejadikan fokus studi untuk pengembangan dan penerapan ML dalam industri *E- Commerce* semakin terbuka lebar. Digitalisasi yang terus berkembang, peningkatan volume data transaksi, serta ketersediaan berbagai platform teknologi *open source* memberikan peluang besar bagi perusahaan untuk berinovasi dalam sistem prediksi permintaan. Penerapan ML juga dapat menjadi keunggulan kompetitif yang membantu perusahaan dalam meningkatkan efisiensi operasional, mempercepat pengambilan keputusan, dan memberikan pengalaman pelanggan yang lebih baik. ML dalam *E-Commerce* menjadi peluang besar untuk berinovasi. Seiring digitalisasi yang semakin masif dan ketersediaan platform *open source*, ML menjadi keunggulan kompetitif dengan meningkatkan efisiensi operasional, percepatan pengambilan keputusan serta pengalaman pelanggan. Hal ini didukung oleh Richard & Kráľ (2025),

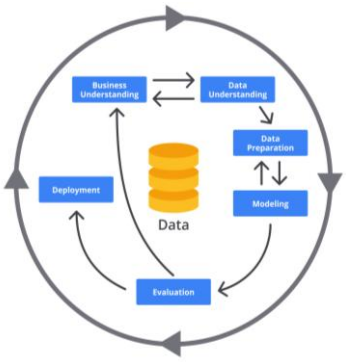
yang menunjukkan bahwa AI/ML mendorong keunggulan dalam *E-Commerce* melalui analitik data *real-time*, personalisasi, dan otomatisasi, meskipun membutuhkan manajemen isu seperti kualitas data dan kekurangan SDM ahli (Richard, 2025).

Penelitian ini bertujuan untuk membandingkan performa algoritma Random Forest, XGBoost, dan Stacking Ensemble dalam memprediksi permintaan produk E-Commerce berbasis data historis, serta menentukan model prediksi yang paling akurat dan optimal untuk diterapkan sebagai solusi pendukung pengambilan keputusan berbasis data.

Pemanfaatan teknologi ML diharapkan mampu memprediksi permintaan produk *E-Commerce* dan menjadi strategi yang potensial untuk perusahaan dalam memprediksi permintaan melalui analisis perbandingan terhadap beberapa algoritma machine learning terkemuka, seperti *Random Forest, XGboost* dan *Stacked Ensembly,* sehingga pendekatan ini menjadi solusi untuk memprediksi pola permintaan konsumen.

METODOLOGI

Penelitian ini menerapkan pendekatan *Cross-Industry Standard Process for Data Mining* (CRISP-DM) sebagai kerangka kerja utama dalam pengembangan model prediksi.



Gambar 1.Tahapan CRISP-DM

CRISP-DM terdiri atas enam fase utama, yaitu *Business Understanding*, *Data Understanding*, *Data Preparation*, *Modeling*, *Evaluation*, dan *Deployment*. Adapun penerapan masing-masing fase dalam penelitian ini sebagai berikut.

Pemahaman Bisnis (*Bussines Understanding*)

Tahap pemahaman bisnis berfokus pada pemahaman konteks bisnis, perumusan tujuan analitik, serta penetapan kriteria keberhasilan yang terukur. Pengelolaan permintaan produk *E-commerce* menggunakan pendekatan prediktif yang akurat agar proses manajemen persediaan dapat berjalan secara efisien dan berbasis data.

Penelitian ini melakukan analisis komparatif terhadap tiga algoritma *machine learning*, yaitu Random Forest Regressor**,** XGBoost**,** dan Stacking Ensemble dalam prediksi permintaan produk pada sektor E-Commerce. Keberhasilan penelitian diukur berdasarkan tiga indikator utama, yaitu: (1) terselenggaranya evaluasi kuantitatif performa ketiga model, (2) teridentifikasinya model dengan tingkat akurasi, keandalan, dan skalabilitas terbaik, serta (3) tersedianya visualisasi hasil prediksi dalam bentuk dasbor analitik yang informatif.

Pemahaman Data (*Data Understanding*)

Tahap pemahaman data meliputi proses pengumpulan, eksplorasi, dan analisis awal data untuk memperoleh pemahaman terhadap karakteristik dataset sebelum dilakukan pemodelan. Dataset yang digunakan dalam penelitian ini merupakan dataset publik *Predict Future Sales* yang diperoleh dari platform Kaggle, yang memuat data penjualan historis periode Januari 2013 hingga Oktober 2015.

Dataset tersebut terdiri dari beberapa berkas yang mencakup informasi transaksi harian, data produk, kategori produk, serta identitas toko. Hasil eksplorasi awal menunjukkan adanya sejumlah permasalahan data, antara lain keberadaan *outlier* pada variabel harga dan jumlah penjualan, serta duplikasi entri pada data toko.

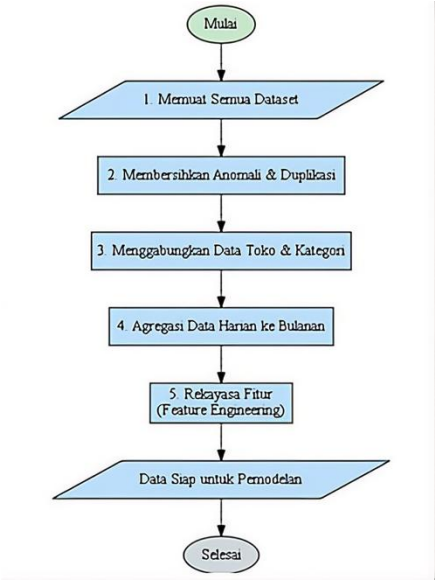
Verifikasi kualitas data dilakukan untuk mengidentifikasi dan menangani potensi permasalahan pada data mentah sebelum tahap persiapan data. Pada tahap ini ditemukan adanya nilai anomali, seperti harga produk bernilai negatif serta jumlah penjualan harian yang sangat ekstrem. Data dengan nilai anomali tersebut dihapus untuk mengurangi distorsi terhadap proses pemodelan dan meningkatkan keandalan hasil prediksi.

Persiapan Data (*Data Preparation*)

Fase persiapan data bertujuan untuk mentransformasikan data mentah menjadi dataset yang akan digunakan dalam proses pemodelan. Tahapan ini diawali dengan pembersihan data, meliputi penghapusan transaksi dengan nilai harga negatif, volume penjualan yang tidak realistis, serta standarisasi identitas toko yang terindikasi duplikat.

Proses selanjutnya dilakukan agregasi data dengan mengonversi data transaksi harian menjadi data penjualan

bulanan berdasarkan kombinasi ID toko**,** ID produk, dan periode waktu**.** Pada tahap rekayasa fitur (*feature engineering*), ditambahkan sejumlah variabel baru, seperti fitur *lag* penjualan, fitur temporal (bulan dan tahun), serta proses *encoding* pada variabel kategorikal. Dataset kemudian dibagi menjadi data latih (Januari 2013-September 2015) dan data uji (Oktober 2015) berdasarkan urutan waktu guna menjaga validitas evaluasi model deret waktu.



Gambar 2. Flowchart Persiapan Data

Pemodelan (*Modelling*)

Tahap pemodelan berfokus pada pembangunan dan pelatihan model prediksi menggunakan teknik *machine learning*. Penelitian ini mengimplementasikan tiga algoritma regresi, yaitu Random Forest Regressor**,** XGBoost**,** dan Stacking Ensemble, yang dipilih berdasarkan kemampuannya dalam menangani data berskala besar, nonlinier, serta memiliki pola temporal. Seluruh model dilatih menggunakan dataset latih yang sama untuk memastikan konsistensi perbandingan performa. Implementasi dilakukan menggunakan bahasa pemrograman Python dengan memanfaatkan pustaka *pandas* untuk pengolahan data, *scikit-learn* untuk pemodelan dan evaluasi, serta *XGBoost* untuk implementasi algoritma *gradient boosting* yang efisien.

```
Bentuk data latih (X_train): (2018633, 11)
Bentuk data validasi (X_valid): (73185, 11)
```

Gambar 3. Bentuk Dataset Latih

Evaluasi Model (*Evaluation*)

Fase evaluasi bertujuan untuk menilai performa model secara kuantitatif dan memastikan kesesuaiannya dengan tujuan penelitian. Evaluasi dilakukan menggunakan tiga metrik regresi, yaitu *Root Mean Squared Error* (RMSE)**,** *Mean Absolute Error* (MAE)**,** dan koefisien determinasi (R^2).

Penerapan (*Deployment*)

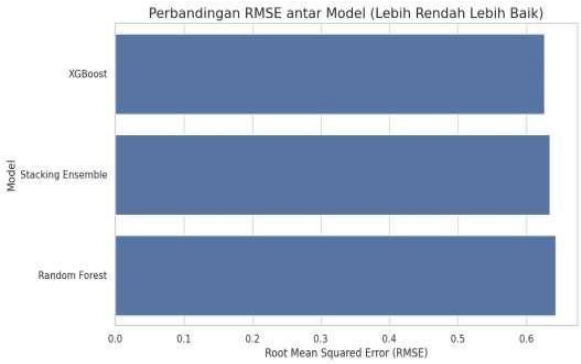
Tahap *Deployment* merupakan fase

akhir dalam metodologi CRISP-DM, model terbaik yang telah divalidasi, diimplementasikan ke dalam sistem prototipe yang bersifat operasional. Seluruh data historis diproses ulang melalui pipeline prapemrosesan dan rekayasa fitur yang konsisten, kemudian digunakan untuk melatih model akhir untuk diperoleh kemampuan generalisasi yang optimal. Model tersebut digunakan untuk menghasilkan prediksi permintaan produk secara kuantitatif, yang kemudian diolah dan divisualisasikan melalui dasbor analitik interaktif. Visualisasi ini menyajikan tren penjualan, pola musiman, serta performa penjualan berdasarkan atribut utama, sehingga mendukung pengambilan keputusan strategis berbasis data dalam *E-Commerce*.

HASIL DAN PEMBAHASAN

Tabel 1. Hasil Metrik Evaluasi Model

No.	Model	RMSE	MAE	R-squared (R^2)
1	*XGBoost*	0.626	0.293	0.630
2	*Stacking Ensemble*	0.634	0.297	0.621
3	*Random Forest*	0.642	0.303	0.611



Hasil evaluasi Tabel 1 menunjukkan bahwa *XGBoost* secara konsisten unggul pada seluruh metrik evaluasi yang digunakan. Hasil ini menunjukkan bahwa model *XGBoost* mampu menghasilkan prediksi yang lebih akurat dan stabil terhadap model pola permintaan produk *E-Commerce*. Rendahnya nilai RMSE dan MAE mencerminkan tingkat kesalahan prediksi yang kecil, sementara nilai R^2 pada model *XGBoost* lebih tinggi dibandingkan kedua model algortima yang lain, menunjukkan kemampuan model dalam menangkap variasi data penjualan secara lebih efektif.

Keunggulan XGBoost memiliki karakteristik algoritman yang menggunakan pendekatan *boosting* secara sekuensial. Setiap pohon keputusan dibangun untuk memperbaiki kesalahan dari model sebelumnya, sehingga model menjadi lebih adaptif terhadap pola non-linear, fluktuasi

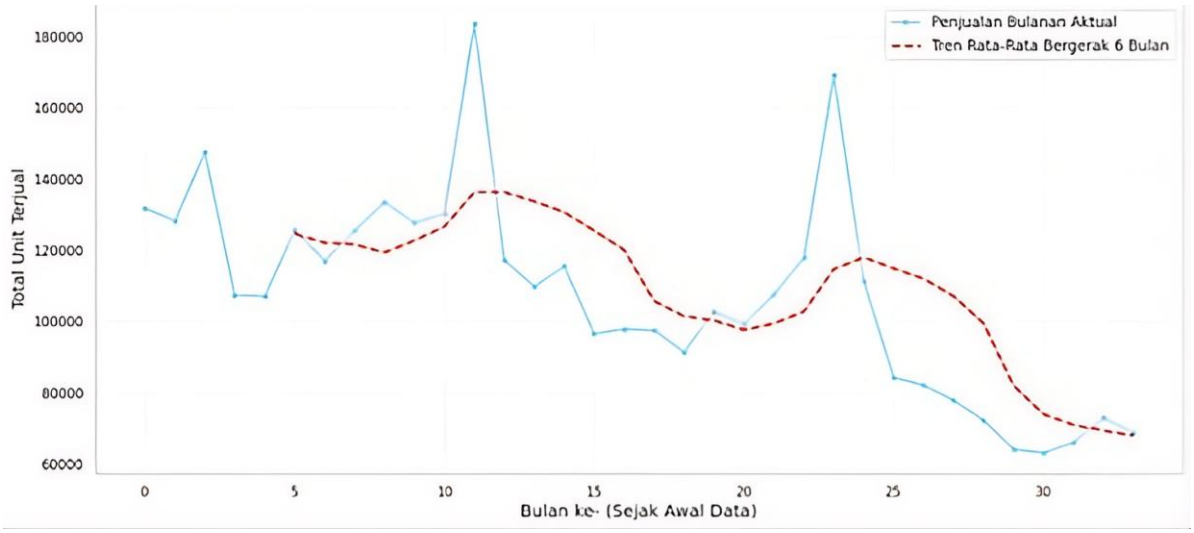
data, dan gangguan yang ditemukan pada data penjualan. Mekanisme regularisasi L1 dan L2 yang dimiliki XGBoost berperan dalam mengendalikan kompleksitas model dan mengurangi risiko *overfitting*, sehingga meningkatkan kemampuan generalisasi terhadap data baru.

Hasil penelitian menunjukkan bahwa XGBoost mampu mengungguli Stacking Ensemble, meskipun secara teoritis pendekatan stacking memiliki potensi untuk menghasilkan performa yang lebih tinggi melalui penggabungan beberapa model dasar. *Stacking Ensemble* belum mampu memberikan peningkatan performa yang signifikan dibandingkan XGBoost secara individual. Hal ini disebabkan oleh konfigurasi *meta-learner* yang belum optimal serta meningkatnya kompleksitas model tanpa diikuti oleh peningkatan akurasi yang sebanding.

Berdasarkan hasil metrik evaluasi model dan perbandingan RMSE antar model, XGBoost terbukti menjadi model yang paling akurat, stabil, dan efisien untuk prediksi permintaan produk E-Commerce, sehingga XGBoost berpotensi menjadi model utama yang layak diterapkan dalam sistem prediksi

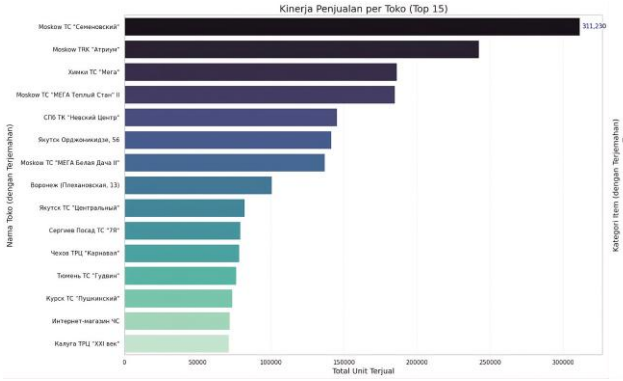
permintaan, baik dari sisi akurasi prediksi maupun efisiensi operasional sistem.

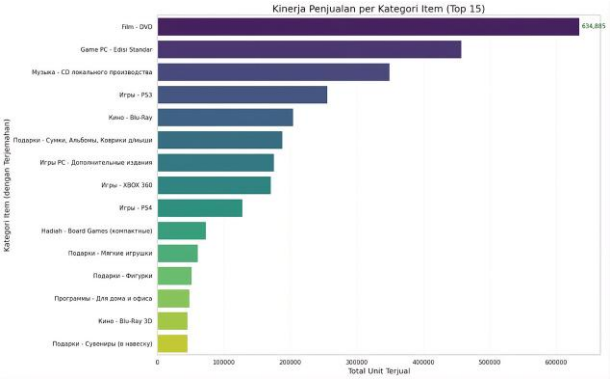
Hasil visualisasi prediksi permintaan ditunjukan dalam bentuk dasbor analitik interaktif dikembangkan sebagai bagian dari sistem operasional penelitian ini. Dasbor menyajikan informasi analitis melalui berbagai visualisasi utama, meliputi tren penjualan bulanan vs jangka panjang, kinerja toko dan kategori produk, heatmap penjualan bulanan pertahun serta siklus 5 produk terlaris. Penyajian berbasis visual ini mendukung proses pengambilan keputusan berbasis data secara objektif dan strategis dalam pengelolaan permintaan dan manajemen persediaan pada lingkungan *E-Commerce*.



Gambar 4. Kurva Tren Penjualan Bulanan vs Tren Jangka Panjang

Grafik pada Gambar 4 menyajikan tren penjualan keseluruhan dari waktu ke waktu dan menjadi indikator penting dalam menilai kinerja bisnis secara makro. Terlihat adanya pola siklus musiman (garis biru) yang konsisten, dengan lonjakan penjualan setiap akhir tahun. Namun, yang lebih penting adalah tren jangka panjang (garis merah) yang menunjukkan kecenderungan menurun dari tahun ke tahun. Puncak penjualan pada akhir 2014 tercatat sekitar 15% lebih rendah dibandingkan puncak tahun 2013, yang merupakan sinyal adanya kontraksi pasar. Penurunan ini dapat disebabkan oleh kombinasi beberapa factor seperti kejenuhan pasar, di mana permintaan terhadap produk-produk utama mulai stagnan, kemudian persaingan yang meningkat dari platform *E-Commerce* digital dan pemain baru di industry, lalu siklus hidup produk, di mana produk-produk unggulan yang sebelumnya mendominasi pasar telah melewati masa puncaknya.



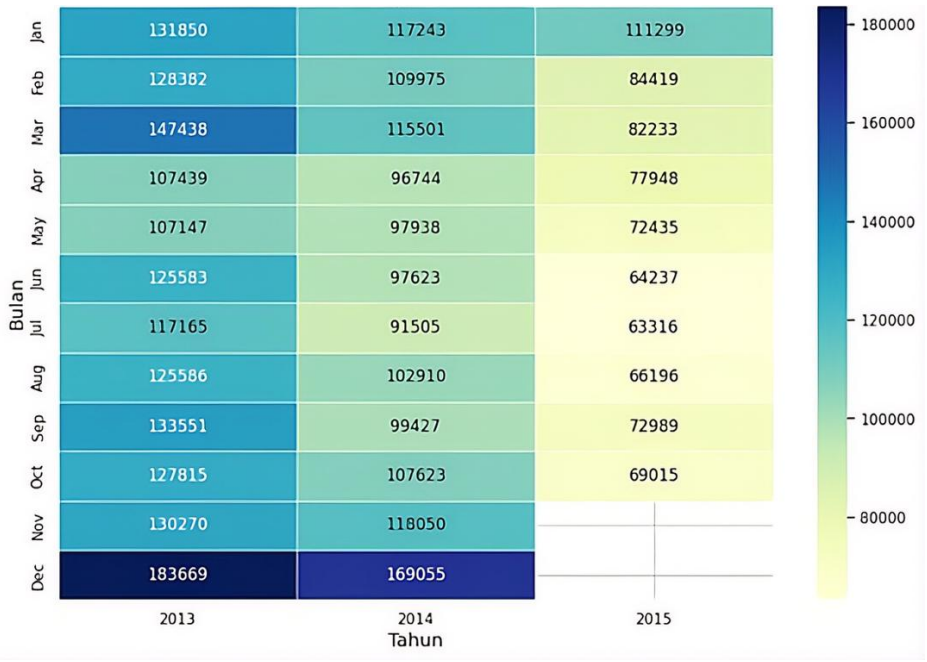


(a) (b)

Gambar 5. (a) Grafik Kinerja Penjualan Per toko (b) Grafik Kinerja Penjualan Per Kategori

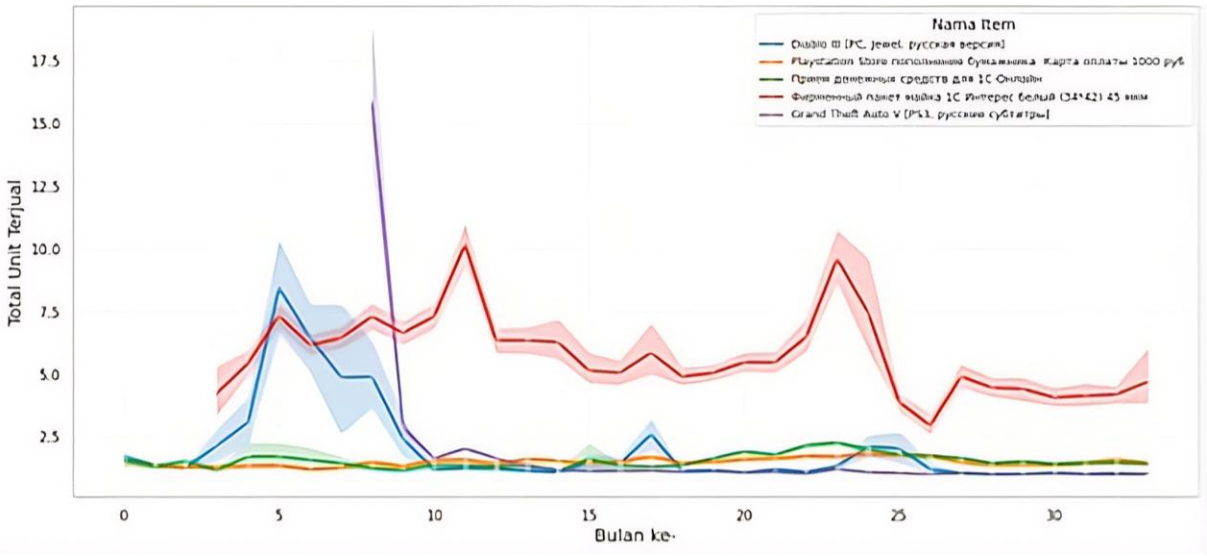
Hasil grafik pada Gambar 5a menampilkan distribusi total penjualan berdasarkan masing-masing toko. Terlihat jelas penerapan Prinsip Pareto (80/20), di mana sebagian kecil toko memberikan kontribusi yang sangat besar terhadap total penjualan perusahaan. Kinerja tiga toko teratas, khususnya yang berlokasi di kota Moskow, jauh melampaui toko-toko lainnya, menunjukan adanya perbedaan kelas atau *tier* dalam jaringan toko. Kinerja superior dari toko-toko teratas dipengaruhi oleh lokasi strategis, seperti di pusat perbelanjaan populer atau wilayah dengan lalu lintas pelanggan yang tinggi, misalnya di "ТЦ «Семеновский»" (TC "Semenovsky"), kemudian demografi pelanggan yang sesuai, yang mendorong tingginya daya beli dan frekuensi pembelian, serta peran sebagai toko unggulan (*flagship stores*) yang menjadi pusat eksposur produk-produk utama perusahaan.

Hasil grafik pada Gambar 5b menunjukkan kontribusi penjualan dari berbagai kategori produk. Hasil menunjukkan bahwa kategori terkait *Game* (seperti PC *Games*, PS3, PS4), Film (Кино), dan Musik (Музыка) mendominasi penjualan. Kategori ini secara konsisten menempati posisi teratas, memperkuat identitas bisnis sebagai penyedia utama produk hiburan. Selain itu, kategori non-inti seperti Hadiah (Подарки) juga masuk dalam lima besar, menunjukkan potensi pasar di luar produk utama. Dominasi kategori hiburan menunjukkan bahwa basis pelanggan inti cenderung terdiri dari konsumen dengan minat tinggi terhadap dunia game dan media hiburan. Permintaan pada kategori ini, khususnya untuk produk-produk rilis baru (AAA titles), sering kali bersifat inelastis, artinya tidak terlalu sensitif terhadap harga. Perilaku konsumen dalam kategori ini umumnya didorong oleh *hype*, tren, dan momentum rilis.



Gambar 6. Head Map Penjualan Bulanan Per Tahun

Grafik heatmap menunjukkan pola musiman yang konsisten tiap tahun, dengan bulan Desember selalu menunjukkan intensitas warna tertinggi, menandakan puncak penjualan. Sebaliknya, bulan-bulan seperti Januari dan Februari secara konsisten menampilkan warna yang lebih terang, menunjukkan penjualan yang rendah. Secara horizontal, terlihat penurunan warna secara bertahap dari tahun 2013 ke 2015, yang mengindikasikan tren penurunan performa tahunan secara keseluruhan. Pola ini merepresentasikan siklus musiman alami dalam industri ritel, terutama yang berkaitan dengan budaya pemberian hadiah di akhir tahun. Penurunan performa tahunan disebabkan oleh kejenuhan pasar, meningkatnya persaingan, dan pergeseran preferensi konsumen terhadap platform digital



Gambar 7. Kurva Siklus Hidup 5 Produk Terlaris

Grafik pada Gambar 7 menunjukkan variasi siklus hidup antar produk. Item 20949 menunjukkan pola khas produk *blockbuster*, dengan penjualan yang melonjak tajam saat awal peluncuran, kemudian menurun secara bertahap. Sementara itu, produk lainnya menunjukkan pola penjualan yang lebih stabil dan berkelanjutan. Temuan ini menunjukkan dinamika umum dalam industri ritel dan hiburan, di mana produk baru biasanya memicu lonjakan penjualan karena efek promosi atau antisipasi pasar. Namun, hanya sedikit produk yang mampu mempertahankan permintaan tinggi secara konsisten. Produk katalog, meskipun tidak spektakuler dalam penjualan, justru sering menjadi tulang punggung pendapatan jangka panjang.

KESIMPULAN

Penelitian ini berhasil dilakukan dengan membandingkan performa algoritma Random Forest, XGBoost, dan Stacking Ensemble dalam memprediksi permintaan produk *E-Commerce* berbasis data historis. Evaluasi menggunakan metrik RMSE, MAE, dan R^2 menunjukkan bahwa XGBoost memiliki performa terbaik**,** dengan nilai RMSE sebesar 0,626**,** MAE sebesar 0,293**,** dan R^2 sebesar 0,630**.** Hasil ini menunjukkan bahwa XGBoost lebih akurat dan stabil dibandingkan model lainnya, sehingga layak diterapkan sebagai solusi prediktif untuk mendukung pengambilan keputusan berbasis data dalam pengelolaan permintaan dan

persediaan *E-Commerce*.

DAFTAR PUSTAKA

Anchuri, S., 2024. Machine Learning-Driven Demand Forecasting: A Comparative Analysis of Advanced Techniques and Real-Time Integration.. *Computer Science & Engineering: Information Technology,* p. 1–14.

Barus, E. S. &. D. D., 2023. Implementasi Metode Random Forest untuk Memprediksi Penjualan Produk. Jurnal Teknik Informasi dan Komputer (Tekinkom). p. 7(2).

Castro, O. B. P. S. J.-S. &. T. D., 2023. Landscape of High-performance Python to Develop Data Science and Machine Learning Applications.

Chunyang Wang, A. S. S. B., 2024. Online sales prediction approach using methodology of CRISP-DM. *ITM Web of Conferences, Volume 59, Article 01006.*

Hobor, L. B. M. P. L. &. K. A., 2025. Comparative Analysis of Modern Machine Learning Models for Retail Sales Forecasting.

Mohammed, S. B. L. F. M. e. a., 2022. The Effects of Data Quality on Machine Learning Performance. arXiv.

Radečić, D., 2022. Is Free Cloud GPU Good Enough for Deep Learning?. *Better Data Science..*

Richard, Ľ. &. K. Š., 2025. Role of Artificial Intelligence and Machine Learning in *E-Commerce*: a Literature Review.. *Advances in Distributed Computing and Artificial Intelligence Journal,* p. 14.

Ridwan, A. M. U. &. N. S., 2024. Optimizing *E-Commerce* Inventory to Prevent Stock Outs Using the Random Forest Algorithm Approach. International Journal Software Engineering and Computer Science. pp. 4(1), 107–120.

Samuel, S. &. M. D., 2023. Computational reproducibility of Jupyter notebooks from biomedical publications. GigaScience.

Saravanos, A. &. C. M. X., 2023. Simulating the Software Development Lifecycle: The Waterfall Model.

Tugay, R. &. O. S. G., 2020. Demand prediction using machine learning methods and stacked generalization..

Wang, M. L. Y. L. G. P. T. R. Y. Y. &. M. K. L., 2024. Unlocking Your Sales Insights: Advanced XGBoost Forecasting Models for Amazon Products

Wang, Y. &. L. L., 2020. Demand Forecasting for *E-Commerce* Using XGBoost. *International Conference on Data Science and Machine Learning,* pp. 102-110.

Yusof, Z. B., 2024. Analyzing the Role of

Predictive Analytics and Machine Learning Techniques in Optimizing Inventory Management and Demand Forecasting for *E-Commerce*. *international Journal of Applied Machine Learning,* pp. 4(11), 16–31.

Yusof, Z. B., 2024. Analyzing the Role of Predictive Analytics and Machine Learning Techniques in Optimizing Inventory Management and Demand Forecasting for *E-Commerce*. International Journal of Applied Machine Learning. pp. 4(11), 16–31..

Zimmermann, A. E. K. E. E. &. B. D. D., 2024. Effectiveness and Utility of Flowcharts on Learning in a Classroom Setting: A Mixed-Methods Study. *American Journal of Pharmaceutical Education.*

Ziyi Xie, Q. X., 2024. Modeling *E-Commerce* retailer demand using Stacking Ensemble and K-means clustering patterns. *Theoretical and Natural Science,* p. 191–196